

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

**«МОСКОВСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
(МОСКОВСКИЙ ПОЛИТЕХ)**

Факультет информационных технологий

Кафедра «Прикладная информатика»

Форма обучения: очная

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

по направлению 09.03.03 «Прикладная информатика»

на тему «Анализ соответствия вакантных ожиданий соискателей и требований работодателей на рынке труда Москвы на основе технологий больших данных»

Студент(ка)

Александр Олегович Климов

Руководитель работы
старший преподаватель.

Ольга Валерьевна Дедехина

ДОПУСКАЕТСЯ К ЗАЩИТЕ

Заведующий кафедрой
профессор, к.э.н.

Станислав Вадимович Суворов

МОСКВА 2025

УТВЕРЖДАЮ

Зав. кафедрой «Прикладная информатика»

С. В. Суворов

ЗАДАНИЕ

На выпускную квалификационную работу (ВКР)

Студента Климова Александра Олеговича группы 211-365

1. Тема: «Анализ соответствия вакантных ожиданий соискателей и требований работодателей на рынке труда Москвы на основе технологий больших данных»

2. Утверждена приказом Московского политехнического университета № _____ от _____

3. Исходные данные к работе: Научная, учебная и методическая литература, открытые данные, бесплатные библиотеки, интернет

4. Содержание ВКР

№ п/п	Наименование раздела	Содержание раздела
1	Аналитическая часть	1.1 Структура рынка труда 1.2 Проблематика несоответствия на рынке труда 1.3 Характеристика исходных данных 1.4 Социально-демографическое распределение соискателей 1.5 Аналитическая постановка задачи поиска несоответствий соискателей и работодателей
2	Теоретическая часть	2.1 Методы анализа несоответствия на рынке труда 2.2 Выбор средств разработки и анализа 2.3 Математическая постановка задачи анализа соответствия ожиданий соискателей и требований работодателей на основе больших данных
3	Практическая часть	3.1 Предобработка данных 3.2 Разведочный анализ данных 3.3 Реализация метрики спроса и предложения на рынке труда в Москве 3.4 Полученные результаты

5. Календарный график выполнения ВКР

№ п/п	Наименование раздела	Дата проведения консультаций
1	Аналитическая часть	08.05.2025
2	Теоретическая часть	20.05.2025
3	Проектная часть	02.06.2025

6. Срок сдачи студентом законченной работы 03.07.2024

Задание выдал 10.03.2025

Задание получил 10.03.2025

Руководитель _____

Студент _____

АННОТАЦИЯ

Тема выпускной квалификационной работы: «Анализ соответствия вакантных ожиданий соискателей и требований работодателей на рынке труда Москвы на основе технологий больших данных».

Работа содержит 67 страниц, 22 рисунков, 3 формулы и 17 источников.

Цель ВКР: разработать метрику несоответствия вакантных ожиданий соискателей и требований работодателей и проанализировать с ее помощью рынок труда в Москве.

Данная работа состоит из трех частей:

В Аналитической части была рассмотрена актуальность данной проблемы, подчеркнут системный и несистемный характер проблемы несоответствия.

В Теоретическом разделе был проведен анализ современных технологий и методов Big Data, обработку естественного языка с помощью машинного обучения. Выбраны инструменты для обработки данных: Python, Pandas, torch, parquet, Jupyter Notebook, SBERT.

В Практической части была реализована метрика, учитывающая три компоненты: соответствие количественных, категориальных и текстовых данных.

Ключевые слова: BIG DATA, PYTHON, NEURAL NETWORK, SBERT, NLP.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	5
1. АНАЛИТИЧЕСКАЯ ЧАСТЬ	8
1.1 Структура рынка труда	8
1.2 Проблематика несоответствия на рынке труда	13
1.3 Характеристика исходных данных	16
1.4 Социально-демографическое распределение соискателей	22
1.5 Аналитическая постановка задачи поиска несоответствий соискателей и работодателей	26
2. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ	28
2.1 Методы анализа несоответствия на рынке труда	28
2.2 Выбор средств разработки и анализа	34
2.3 Математическая постановка задачи анализа соответствия ожиданий соискателей и требований работодателей на основе больших данных	37
3. ПРАКТИЧЕСКАЯ ЧАСТЬ	39
3.1 Предобработка данных	39
3.2 Разведочный анализ данных	41
3.3 Реализация метрики соответствия спроса и предложения на рынке труда в Москве	51
3.4 Полученные результаты	60
ЗАКЛЮЧЕНИЕ	63
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ И ЛИТЕРАТУРЫ	65
ПРИЛОЖЕНИЯ	68

ВВЕДЕНИЕ

Современный мир переживает глубокие трансформации под воздействием цифровизации, автоматизации и новых технологий. Стремительно растет число игроков в экономике и усложняются их взаимоотношения. В таких условиях особенно значимой становится обработка больших данных. Такой подход позволяет не только повысить эффективность принятия решений и сократить расходы, но и получить важнейшие выводы на основе большой выборки.

Несоответствие между требованиями работодателей и ожиданиями соискателей приобретает особую значимость в условиях нарастающего дефицита кадров, который охватывает все более широкие сегменты рынка труда. Одной из ключевых причин актуальности анализа данной проблемы является демографическая ситуация. Как отмечается в исследовании РАНХиГС, Россия сталкивается с последствиями многолетнего демографического спада. Падение рождаемости 1990-х годов и сокращение притока трудовых мигрантов в 2021–2022 годах значительно сократили предложение рабочей силы, усугубив нехватку как квалифицированных, так и неквалифицированных специалистов [7].

В результате к 2025 году основную часть рабочей силы составляют представители поколения «миллениалов» (рожденные с 1981 по 1996 годы), характеризующиеся иными трудовыми мотивациями. Они чаще меняют места работы, стремятся к гибкости и самореализации, предъявляя более высокие требования к качеству трудовых условий, чем предшествующие поколения [7]. Это дополнительно обостряет проблему адаптации системы подготовки кадров к новым запросам и ценностным ориентирам рабочей силы.

Дефицит кадров проявляется в самых различных отраслях, от традиционного производства и сельского хозяйства до высокотехнологичных

направлений и сферы здравоохранения [12]. Работодатели вынуждены повышать заработную плату, улучшать условия труда, организовывать обучение и переобучение сотрудников внутри компаний, но даже эти меры не всегда позволяют эффективно восполнить нехватку необходимых специалистов. В условиях ограниченности трудовых ресурсов все более острой становится необходимость рационального использования доступного кадрового потенциала, что невозможно без глубокого анализа соответствия компетенций соискателей требованиям работодателей.

Существенным осложняющим фактором является также несбалансированность профессиональной подготовки, что фиксируется в исследованиях несоответствия между рынком труда и рынком образовательных услуг [9]. Многие выпускники, особенно в сферах гуманитарного образования, сталкиваются с трудностями трудоустройства по специальности, предъявляя при этом завышенные зарплатные ожидания, что подтверждается результатами социологических исследований [1].

Дополнительным источником конфликтов между работодателями и соискателями являются различия в ожиданиях сторон относительно заработной платы, условий труда, графиков занятости, а также требований к опыту работы. Как подчеркивается в исследовании Высшей Школы Экономики, современный рынок труда насыщен как системными, так и несистемными факторами, порождающими конфликты несоответствия [10]. Системные конфликты формируются под воздействием макроэкономических процессов, таких как несоответствие структуры спроса и предложения, а несистемные обусловлены индивидуальными карьерными стратегиями и корпоративными практиками.

В условиях обострения дефицита рабочей силы эффективное функционирование рынка труда требует качественного анализа текущего

положения с целью выявления ключевых зон несоответствия. Такой анализ позволяет формировать обоснованные рекомендации для образовательных учреждений и работодателей, направленные на выравнивание структуры подготовки кадров, развитие гибких образовательных программ, совершенствование профориентационной работы и корректировку корпоративной политики в части подбора персонала.

Таким образом, исследование несоответствия между требованиями работодателей и ожиданиями соискателей в условиях дефицита кадров приобретает стратегическую значимость как для социальной стабильности, так и для повышения конкурентоспособности экономики в целом.

1. АНАЛИТИЧЕСКАЯ ЧАСТЬ

1.1 Структура рынка труда

1.1.1 Определение рынка труда

Рынок труда — это система, в рамках которой происходит взаимодействие между работодателями, предлагающими рабочие места, и соискателями, предоставляющими свою рабочую силу. На рынке труда формируется спрос на рабочую силу со стороны компаний и предложение труда со стороны работников, готовых трудиться за определённую оплату [2]. В отличие от товарного или финансового рынков, рынок труда представляет собой пространство обмена не столько продуктами или капиталом, сколько человеческим капиталом — совокупностью знаний, навыков, умений, компетенций и профессионального опыта.

Согласно современным социолого-экономическим подходам, рынок труда рассматривается как система, включающая в себя не только механизмы найма и увольнения, но и более широкие процессы профессиональной социализации, карьерного роста, профориентации, адаптации работников, регулирования условий труда. Рынок труда — это также поле социального конфликта, где сталкиваются интересы работодателей и соискателей, обусловленные не только экономическими, но и ценностными, нормативными, культурными различиями [10]. Эти конфликты, согласно авторам, могут быть системными (например, возникающими из-за несоответствия спроса и предложения на труд) и несистемными (вызванными индивидуальными ожиданиями и особенностями найма)

Таким образом, рынок труда является сложной многоуровневой системой, функционирующей под воздействием множества переменных. Он представляет собой не только механизм распределения рабочей силы, но и институт, регулирующий социальные отношения в сфере занятости. Его

эффективность определяется не только уровнем занятости и заработной платы, но и степенью удовлетворенности работников и работодателей, наличием возможностей для профессионального роста, прозрачностью найма и мобильностью рабочей силы.

1.1.2 Спрос и предложение на рынке труда

Спрос на рынке труда представляет собой потребность работодателей в определённом количестве работников с нужными навыками и квалификацией для производства товаров и услуг. Это выражается в количестве открытых вакансий в конкретный период времени, которые компании стремятся заполнить [14]. В микроэкономическом аспекте спрос на труд зависит от заработной платы: при её повышении работодатели стремятся сократить число нанимаемых, а при снижении — готовы увеличить набор персонала. Также на спрос влияет потребность в конечной продукции, доступность заменяющих факторов производства, уровень квалификации и предельная доходность труда.

Спрос на рабочую силу формируется на основе потребностей экономики в персонале, способном обеспечивать воспроизводство валового внутреннего продукта. При этом важнейшим фактором, влияющим на спрос, выступает соотношение темпов роста ВВП и производительности труда. Если темпы роста ВВП превышают темпы роста производительности труда, то происходит увеличение спроса на рабочую силу, что соответствует сценарию экстенсивного экономического роста. Если же производительность труда растёт быстрее ВВП, спрос на рабочую силу сокращается. Таким образом, динамика спроса напрямую зависит от характера экономического развития и инвестиционной политики государства. Например, при темпах роста ВВП на уровне 7% и росте производительности труда около 7,5% спрос на труд фактически снижается [4].

Предложение на рынке труда, в свою очередь, формируется за счёт экономически активного населения, которое включает в себя как занятых, так и безработных, способных и готовых приступить к работе. Основным фактором, ограничивающим рост предложения, выступает демографическая ситуация. Равновесие на рынке труда устанавливается в точке пересечения E_0 кривых спроса и предложения на рабочую силу (рис. 1.1) [15]. Эта точка характеризуется тем, что количество труда, которое работодатели готовы приобрести при определённой заработной плате, совпадает с количеством труда, которое работники готовы предоставить. Соответственно, в условиях идеальной конкуренции эта точка определяет равновесную (рыночную) заработную плату и равновесный объём занятости.




Рисунок 1.1 Кривые спроса и предложения на рынке труда

Однако равновесие на рынке труда редко достигается автоматически, так как оно подвержено влиянию множества факторов — институциональных, демографических, образовательных, территориальных. Даже в условиях

рыночного баланса могут сохраняться системные конфликты — в первую очередь, из-за расхождений в зарплатных ожиданиях соискателей и работодателей, а также вследствие непрозрачности процессов найма [10]. При этом конкуренция между кандидатами ограничена заранее заданными рамками вакансий, что снижает гибкость установления равновесной цены труда.

1.1.3 Особенности московского рынка труда

Рынок труда Москвы обладает рядом уникальных структурных особенностей, которые отличают его от большинства регионов России. Согласно исследованию Поляковой М. В., московский рынок труда характеризуется высокой экономической активностью населения, крайне низким уровнем безработицы и значительной долей занятости в секторах услуг и высококвалифицированного труда [8].

Во-первых, уровень безработицы в Москве традиционно является самым низким среди субъектов Российской Федерации. Так, в 2013 году зарегистрированная безработица составила всего 0,38 % от численности экономически активного населения, что существенно ниже как среднероссийского уровня (более 5 %), так и соответствующих показателей во многих развитых странах. Такая низкая безработица обусловлена, в том числе, высоким уровнем внутренней трудовой миграции в столицу, что создает дополнительное давление на рынок, но при этом позволяет поддерживать высокий уровень занятости [8].

Во-вторых, структура занятости в Москве смещена в сторону сферы услуг и высокодоходных отраслей. Наибольшее количество трудоустроенных сосредоточено в оптовой и розничной торговле (25 %), финансовом и консалтинговом секторах (23 %), а также в операциях с недвижимостью. Промышленные и обрабатывающие отрасли играют менее значительную роль

(около 8 %), что объясняется как урбанистическим характером столицы, так и постепенным выведением производственных мощностей за пределы города.

Третьей особенностью является наблюдаемое структурное несоответствие между предложением и спросом. Несмотря на превышение количества вакансий над числом официально зарегистрированных безработных, закрытие рабочих мест не всегда осуществляется оперативно. Это связано как с недостаточной привлекательностью некоторых вакансий, так и с профессионально-квалификационным несоответствием между соискателями и требованиями работодателей.

Стоит также подчеркнуть, что, несмотря на наличие большого количества вакансий, рынок труда испытывает напряженность (рис. 1.2) из-за того, что структура предложения рабочей силы не соответствует структуре спроса. На одного безработного по состоянию на конец 2022 года приходилось более трёх вакансий, однако многие из них остаются незакрытыми из-за отсутствия соискателей с требуемыми квалификациями [6]. Особенно выражено это несоответствие в рабочих и технических профессиях. Так, на одного безработного квалифицированного рабочего в промышленности, строительстве и транспорте приходится более 9 вакансий. В то же время среди зарегистрированных безработных преобладают лица с гуманитарным образованием — экономисты, юристы, специалисты в области администрирования, по которым спрос минимален. Например, на одного врача приходится до 66 вакансий, тогда как по юристам наблюдается избыток предложений и отсутствие спроса со стороны работодателей.




Рисунок 1.2 Напряженность на рынке труда в Москве

Причины сложившейся ситуации включают инерционность системы профессионального образования, демографический спад, недостаточную мобильность рабочей силы, а также низкую привлекательность вакансий, особенно в бюджетной сфере. Важным институциональным фактором структурной безработицы является занижение цены труда на «нормативные» профессии — врачи, преподаватели, инженеры, научные работники.

Таким образом, рынок труда Москвы представляет собой динамичную и относительно сбалансированную систему, однако сталкивается с типичными для мегаполисов проблемами: поляризация спроса, профессионально-квалификационное несоответствие, перегрев отдельных секторов и дисбаланс между миграционным притоком и потребностями экономики. Последнее стало особенно критичным именно в последние годы, так как с 2022 года наблюдается резкий спад трудовой эмиграции в столицу [12].

1.2 Проблематика несоответствия на рынке труда

Проблематика несоответствия спроса и предложения на рынке труда в Москве является одной из ключевых причин возникновения структурной безработицы, снижения производительности труда и ограничений для

экономического роста. Для столичного рынка труда характерны выраженные структурные диспропорции в профессионально-квалификационном разрезе. Так, согласно исследованиям ВНИИ труда Минтруда России, наблюдается значительный дефицит кадров в строительстве, здравоохранении, сфере информационных технологий, при этом на рынке преобладают безработные с гуманитарными и юридическими специальностями, на которых спрос крайне низок [6].

Также выявлен конфликт между содержанием профессионального образования и реальными потребностями рынка труда. Образовательные учреждения готовят специалистов, не востребованных экономикой, что порождает массовое трудоустройство «не по специальности» и сверхквалификацию [9].

Еще одним важным аспектом проблемы является влияние демографических и миграционных факторов. Сокращение численности молодежи, старение рабочей силы и внутренние миграции формируют неравномерность предложения труда между регионами и усугубляют кадровый дефицит в мегаполисе, особенно в массовых профессиях [4, 12]. Цифровизация, автоматизация и внедрение ИИ способствуют росту спроса на новые компетенции, которых рынок не успевает предложить. Это усугубляет проблему несоответствия, особенно среди ИТ-специалистов начального уровня и рабочих без цифровых навыков.

Выделяются следующие виды несоответствия спроса и предложения на рынке труда:

- 1) Квалификационное несоответствие. Это наиболее часто обсуждаемый и исследуемый тип. Он проявляется тогда, когда уровень профессиональной подготовки соискателей не соответствует требованиям работодателей. Особенно остро он наблюдается в случае с

техническими и рабочими специальностями, где спрос существенно превышает предложение. В то же время гуманитарные, юридические и экономические специальности перенасыщены кадрами, спрос на которых ограничен [6].

- 2) Зарплатное несоответствие. Данный тип несоответствия выражается в расхождении между ожидаемым уровнем оплаты труда соискателей и реальными предложениями на рынке. Студенты и молодые специалисты часто имеют завышенные ожидания по доходу, что не соответствует рыночной ситуации, особенно в гуманитарных и бюджетных сферах [1]. Аналогично, работодатели занижают оплату труда в социально значимых профессиях, таких как здравоохранение и образование, что также провоцирует дефицит кадров.
- 3) Несоответствия по опыту работы. Даже при наличии соответствующего образования работодатели часто требуют опыт работы, что исключает выпускников и начинающих специалистов из числа подходящих кандидатов [9]. Это ограничение порождает так называемый «парадокс первого трудоустройства» — соискатель не может получить опыт без работы, и работу без опыта.
- 4) Ценностные несоответствия. Современные соискатели, особенно молодежь, все чаще ориентируются на гибкий график, возможность самореализации и комфортную рабочую атмосферу, тогда как работодатели не всегда могут или готовы соответствовать этим ожиданиям [1]. Это приводит к отказу от потенциально подходящих вакансий и усилению текучести кадров.

1.3 Характеристика исходных данных

Для проведения анализа соответствия ожиданий соискателей и требований работодателей на рынке труда Москвы были использованы два массива данных: резюме соискателей и вакансий работодателей. Данные взяты из открытого банка данных «Работа в России» [3]. Оба набора данных деперсонализированы и охватывают предложения и запросы участников столичного рынка рабочей силы, что позволяет провести детальный сравнительный анализ структурных характеристик спроса и предложения труда.

Набор данных с резюме содержит 10 144 445 строк, в каждой из которых содержится запись с анкетой соискателя, состоящая из 31 колонки или 314 477 795 ячеек общим объемом 23,02Гб (рис. 1.3).

	id	candidateId	stateRegionCode	locality	localityName	birthday	gender	age	positionName	dateCreate	...	languageKnowledge	relocation
5	1989bab6-b0b3-11e6-9d39-ef76bd2a03c1	18fbc170-a190-11e6-841a-ef76bd2a03c1	77000000000000	77000000000000	г-Москва	1989-05-26T00:00:00+0400	Женский	35	Архивариус, -делопроизводитель.	2016-11-22T15:56:35+0300	...		Не-готов-к-переезду
14	1989a75a-7649-11e5-8f00-833b590698f7	27700f90-7643-11e5-8f00-833b590698f7	77000000000000	77000000000000	г-Москва	1992-08-02T00:00:00+0400	Женский	32	инженер	2018-02-21T13:16:08+0300	...	[{"codeLanguage": "Английский", "level": "B2 — ...	Не-готов-к-переезду
20	19899e90-9dcf-11e7-9620-4376a32b3145	eb785b50-9dbe-11e7-9620-4376a32b3145	77000000000000	77000000000000	г-Москва	1976-09-29T00:00:00+0300	Мужской	48	Сотрудник-в-офис	2017-09-20T09:44:07+0300	...	[{"codeLanguage": "Английский", "level": "A1 — ...	Не-готов-к-переезду
68	198957b0-c682-11e6-a0b8-716c765c9fe3	7426f9a0-9d06-11e6-b6d2-e73e8fa159bf	77000000000000	77000000000000	г-Москва	2002-08-28T00:00:00+0400	Мужской	22	Младший-инженер-разработчик	2024-02-08T12:11:53+0300	...		Не-готов-к-переезду
167	1988be50-74c7-11e6-94b5-c7bd3a8c3ec7	c672ef90-74c3-11e6-804e-e73e8fa159bf	77000000000000	77000000000000	г-Москва	1987-07-17T16:00:00+0400	Женский	37	Сменный-мастер	2023-10-27T15:48:17+0300	...	[{"codeLanguage": "Русский", "level": "A1 — на...	Не-готов-к-переезду
...	...	...	...	...	...	...	...	...	...	...	...	...	...
10376701	812cc8b0-65f9-11e6-b69f-b905beff617a	27543690-65f7-11e6-b69f-b905beff617a	77000000000000	77000000000000	г-Москва	1991-07-16T15:00:00+0300	Женский	33	экономист-в-банке	2021-02-03T11:26:25+0300	...	[{"codeLanguage": "Английский", "level": "B2 — ...	Не-готов-к-переезду
10376706	80f361c0-1f3f-11f0-a47a-c7bd3a8c3ec7	a5bb7f80-1f3d-11f0-8ab0-03a6ffa13304	77000000000000	77000000000000	г-Москва	1985-01-17T15:00:00+0300	Женский	40	Бухгалтер	2025-04-22T09:03:25+0300	...		Не-готов-к-переезду
10376713	804d6e80-1f80-11f0-894d-716c765c9fe3	0ec7c980-1f7e-11f0-a2c0-a78d29e6deb7	77000000000000	77000000000000	г-Москва	1976-04-20T15:00:00+0300	Женский	49	Главный-специалист-по-охране-окружающей-среды	2025-04-22T16:48:42+0300	...	[{"codeLanguage": "Русский", "level": "C2 — в ...	Не-готов-к-переезду
10376732	80676620-1ed6-11f0-b493-e7f4617514ed	b31c2db0-1ece-11f0-a3e6-4db136472102	77000000000000	77000000000000	г-Москва	1967-12-03T15:00:00+0300	Женский	57	врач-педиатр	2025-04-21T20:31:47+0300	...	[{"codeLanguage": "Английский", "level": "B1 — ...	Не-готов-к-переезду

Рисунок 1.3 Исходный набор данных с резюме

Набор данных с вакансиями содержит 607 594 строки, в каждой из которых отражены требования работодателя, состоящие из 44 колонок или 26 743 136 ячеек общим объемом 2,04Гб (рис. 1.4).

vacancyName	codeProfession	codeProfessionalSphere	professionalSphereName	vacancyAddress	vacancyAddressHouse	vacancyAddressAdditionalInfo	geo	...	hireDate	workPla
Продавец-кассир	None	Sales	Продажи, закупки, снабжение, торговля	Город Москва, 1-й Грайвороновский проезд	None	Россия, г Москва, 1-й Грайвороновский проезд, ...	{\"latitude\": 55.720874, \"longitude\": 37.725595}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Главный специалист направления PDM систем	209204	InformationTechnology	Информационные технологии, телекоммуникации, с...	Город Москва, Озерковская набережная, 30	30	ООО АПРОСА Информационные технологии	{\"latitude\": 55.738019, \"longitude\": 37.638}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Экономист	277409	AccountingTaxesManagement	Бухгалтерия, налоги, управленческий учет	Город Москва, Хромова улица, дом 24	дом 24	None	{\"latitude\": 55.799973, \"longitude\": 37.719998}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Главный специалист отдела поддержки бизнеса	208894	InformationTechnology	Информационные технологии, телекоммуникации, с...	Город Москва, 1812 года улица, 14	14	ООО АПРОСА Информационные технологии	{\"latitude\": 55.742924, \"longitude\": 37.520132}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Врач-офтальмолог	204484	Medicine	Здравоохранение и социальное обеспечение	Город Москва, Трехгорный Вал улица, дом 6А	дом 6А	None	{\"latitude\": 55.768884, \"longitude\": 37.56079}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
...	...	...	...	...	...	...	...	...	...	...
Инженер-технолог ПТО	224469	Industry	Производство	Город Москва, Южнопортовая улица, дом: Д. 7А;	дом: Д. 7А;	None	{\"latitude\": 55.708191, \"longitude\": 37.691656}	...	None	{\"workPlaceDisabilityGroup\": \"Функции сердечника\", \"workPlaceOrdinary\": true}
Экономист в группу финансового сопровождения Д...	277288	AccountingTaxesManagement	Бухгалтерия, налоги, управленческий учет	Город Москва, Полимерная улица, дом 8	дом 8	None	{\"latitude\": 55.746061, \"longitude\": 37.799706}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Слесарь-сантехник	None	WorkingSpecialties	Рабочие специальности	Город Москва, 7	7	Москва, Ботанический переулок, 7	{\"latitude\": 55.778336, \"longitude\": 37.637802}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Изготовитель мясных полуфабрикатов	123978	Industry	Производство	Город Москва, Пермская улица, дом: 5;	дом: 5;	Щелковское шоссе, д91, корп3, кв446	{\"latitude\": 55.82134, \"longitude\": 37.733841}	...	None	{\"workPlaceForeign\": false, \"workPlaceOrdinary\": true}
Плотник	166719	BulldingRealty	Строительство, ремонт, стройматериалы, недвижки...	Город Москва, Тишинский Ср. переулок, 28	28	123557, г. Москва, пер. Тишинский Ср., д. 28, С...	{\"latitude\": 55.770517, \"longitude\": 37.575486}	...	None	{\"workPlaceForeign\": true, \"workPlaceOrdinary\": true}

Рисунок 1.4 Исходный набор данных с вакансиями

Важно отметить, что имеющиеся данные охватывают не только московский регион, но и весь центральный федеральный округ РФ. Также, имеются строки с неправильным форматированием, неправильно заполненными данными и прочими ошибками измерения. Это критически важно учитывать при первичной предобработке.

1.3.1 Характеристика набора данных с резюме

Ниже приведен список колонок в наборе данных с резюме:

- 1) Водительские права – признак, содержащий информацию о наличии у соискателя водительских прав и их категорию.
- 2) Возраст – возраст соискателя.
- 3) Волонтерство – бинарный признак, характеризующий участие соискателя в волонтерской деятельности.
- 4) Гибкие навыки – список гибких (социальных) навыков у соискателя.
- 5) Готовность к командировкам – бинарный признак, характеризующий готовность соискателя к командировкам.

- 6) Готовность к переобучению – бинарный признак, характеризующий готовность соискателя к возможному переобучению.
- 7) График работы – список графиков работы, в которых заинтересован соискатель.
- 8) Дата публикации – дата публикации резюме.
- 9) Дата рождения – дата рождения соискателя.
- 10) Дополнительная информация – дополнительная информация, которую предоставил соискатель.
- 11) Другие сертификаты – дополнительные сертификаты соискателя.
- 12) Жесткие навыки – список жестких (прикладных) навыков у соискателя.
- 13) Знание иностранных языков – список иностранных языков, а также уровень их знания у соискателя.
- 14) Максимальная зарплата – максимальная зарплата, на которую претендует соискатель.
- 15) Минимальная зарплата – минимальная зарплата, на которую претендует соискатель.
- 16) Навыки – навыки, выбранные соискателем из заранее определенного списка.
- 17) Наименование позиции – название позиции, на которую претендует соискатель.
- 18) Образование – список образований у соискателя.
- 19) Опыт – опыт работы у соискателя.
- 20) Переезд – бинарный признак, характеризующий возможность переезда у соискателя.
- 21) Подтверждение волонтерства – бинарный признак, характеризующий участие соискателя в волонтерской деятельности.

- 22) Подтверждение справки от нарколога – бинарный признак, характеризующий наличие подтвержденной справки от нарколога у соискателя.
- 23) Подтверждение участия в «Абилимпикс» – бинарный признак, удостоверяющий участие соискателя в движении «Абилимпикс».
- 24) Подтверждение участия в «World Skills» – бинарный признак, удостоверяющий участие соискателя в движении «World Skills».
- 25) Пол – пол соискателя.
- 26) Предпринимательская деятельность – список предпринимательских деятельностей, в которых участвовал соискатель.
- 27) Смены – список сменных графиков, к которым готов соискатель.
- 28) Справка от нарколога – бинарный признак, характеризующий у наличие у соискателя справку от нарколога.
- 29) Типичная позиция – название позиции из заранее определенного списка.
- 30) Участие в «Абилимпикс» – бинарный признак, характеризующий участие соискателя в движении «Абилимпикс».
- 31) Участие в «World Skills» – бинарный признак, характеризующий участие соискателя в движении «World Skills».

1.3.2 Характеристика набора данных с вакансиями

Ниже приведен список колонок в наборе данных с резюме:

- 1) Код профессии – код профессии, обобщающий разные названия типовых позиций.
- 2) Код сферы профессии – код сферы профессии, обобщающий разные названия сфер.
- 3) Социальные группы – список групп социальной защиты, которым доступна работа (инвалид, ветеран, родитель-одиночка и т. д.).
- 4) Знание языка – язык и его уровень, необходимый для работы.
- 5) Тип занятости – типы занятости, предоставляемые работодателем.
- 6) Требования образования – тип и специализация необходимого образования.
- 7) Жесткие навыки – список необходимых жестких навыков.
- 8) Гибкие навыки – список необходимых гибких навыков.
- 9) Навыки – список необходимых для работы навыков.
- 10) Типичная позиция – название типичной позиции из заранее определенного списка.
- 11) Опыт работы – требования по опыту работы на такой же должности.
- 12) График работы – список возможных графиков работы.
- 13) Премия – размер премии и ее периодичность.
- 14) Другие преимущества – другие преимущества, предоставляемые работодателем.
- 15) Карьерные перспективы – бинарный признак, характеризующий возможность карьерных перспектив в компании.
- 16) Необходимость медкнижки – бинарный признак, характеризующий необходимость медицинской книжки.

- 17) Приоритетная вакансия – бинарный признак, характеризующий приоритетность вакансии в компании.
- 18) Водительские права – список водительских прав, необходимых для работы по вакансии.
- 19) Возможность переобучения – бинарный признак, характеризующий возможность переобучения внутри компании.
- 20) Оплата во время обучения – размер заработной платы во время обучения и переобучения внутри компании.
- 21) Компенсация транспорта – тип компенсации транспортных расходов (топливо, проезд, полная компенсация).
- 22) Размер компании – характерный размер компании.
- 23) Рабочие места – количество рабочих мест по позиции.
- 24) Трудоустройство узбекистанцев – бинарный признак, характеризующий возможность трудоустройства граждан из Узбекистана.
- 25) Дата публикации – дата публикации вакансии.
- 26) Возможность проживания – бинарный признак, характеризующий возможность проживания за счет работодателя.
- 27) Тип проживания – тип жилья, предоставляемый работодателем.
- 28) Трудоустройство иностранцев – бинарный признак, характеризующий возможность трудоустройства иностранцев.
- 29) Квота – бинарный признак, характеризующий квотируемость рабочего места.
- 30) Программа мобильности – бинарный признак, характеризующий принадлежность вакансии программе мобильности.
- 31) Требования – список требований к соискателю.

- 32) Дополнительный требования – список дополнительных требований к соискателю.
- 33) Минимальная зарплата – нижняя граница зарплатной вилки.
- 34) Максимальная зарплата – верхняя граница зарплатной вилки.
- 35) Квалификации – список квалификаций, необходимый для трудоустройства.
- 36) Ответственность – список зон ответственности соискателя.
- 37) Дата трудоустройства – дата возможного трудоустройства после прохождения собеседования.
- 38) Медицинская справка – список медицинских справок, необходимых для трудоустройства.
- 39) Комментарий к графику – комментарий к графику работы, оставленный работодателем.
- 40) Продолжительность испытательного срока – количество дней испытательного срока.
- 41) Смена – размер смены при сменном графике работы.
- 42) Медицинские документы – медицинские документы, необходимые для трудоустройства.
- 43) Привилегии – привилегии, предоставляемые работодателем.
- 44) Условия работы – комментарий работодателя об условиях работы на вакансии.

1.4 Социально-демографическое распределение соискателей

При изучении данных стоит выделить особое внимание демографическому распределению соискателей в выбранном наборе данных. На диаграмме ниже (рис. 1.5) показано такое распределение. На оси ординат отмечены возрастные группы включая нижнюю границу и не включая верхнюю. Стоит отметить, что полученные данные уже представляют интерес.

Также видно, что подтверждаются тенденции из исследования трудового рынка РАНХиГС [7].




Рисунок 1.5 Демографическая пирамида соискателей в наборе данных

Большое значение для работодателей при выборе кандидата имеет опыт работы в данной сфере. Распределение соискателей по возрасту и опытно-возрастная структура являются ключевыми элементами при анализе состояния и динамики рынка труда. Они позволяют понять, каков реальный состав рабочей силы, выявить его демографические особенности и оценить потенциальные риски и дефициты кадров в различных возрастных группах. Возраст соискателя отражает стадию его профессиональной карьеры и жизненного цикла, что оказывает непосредственное влияние на его профессиональные амбиции, предпочтения в сфере занятости, готовность к переобучению, мобильность и гибкость в выборе профессиональных направлений. Молодые соискатели, как правило, обладают относительно

небольшим профессиональным опытом, однако часто демонстрируют высокую адаптивность, готовность к освоению новых навыков и более широкие ожидания по поводу профессиональной реализации. Напротив, старшие возрастные группы характеризуются значительным профессиональным стажем, но вместе с тем могут обладать ограниченной мобильностью и меньшей гибкостью в освоении новых технологий и профессий.

Образование традиционно рассматривается работодателями как один из ключевых индикаторов профессиональной квалификации и потенциальной продуктивности соискателя [16]. Наличие диплома о высшем или среднем профессиональном образовании свидетельствует о базовом уровне теоретических знаний и способности к системному обучению, что особенно важно в отраслях, требующих профильной подготовки, таких как медицина, инженерия, юриспруденция, финансы и образование. Формальное образование остаётся важным критерием отбора, особенно на этапе первичной фильтрации резюме, где автоматизированные системы могут учитывать наличие и уровень образования как обязательное условие прохождения в следующий этап отбора.

Ниже представлена диаграмма (рис. 1.6) распределения образования у соискателей. Подавляющее большинство соискателей имеет высшее образование, что может говорить о нерепрезентативности набора данных, согласно исследованиям [11].




Рисунок 1.6 Распределение соискателей по образованию

Однако важно отметить, что работодатели всё чаще оценивают не только сам факт получения образования, но и его релевантность, уровень учреждения, форму обучения и наличие дополнительных квалификаций. В условиях стремительно меняющихся требований рынка труда, особенно в технологических отраслях, большое значение приобретает не только диплом, но и наличие курсов повышения квалификации, участие в стажировках и образовательных программах, демонстрирующих готовность к непрерывному профессиональному развитию [11, 16]. При этом репутация вуза также оказывает влияние на восприятие кандидата: диплом из ведущих университетов нередко рассматривается как косвенное свидетельство высокого уровня подготовки и конкурентоспособности.

Для некоторых работодателей особенно важно наличие профильного образования, соответствующего должности, на которую претендует кандидат. Например, в педагогике, медицине или юриспруденции невозможно получить

доступ к профессии без соответствующего диплома. В других сферах, особенно в частном секторе и в быстрорастущих отраслях, акцент может смещаться на практические навыки и опыт, но при прочих равных условиях наличие качественного образования остаётся преимуществом.

1.5 Аналитическая постановка задачи поиска несоответствий соискателей и работодателей

Современный рынок труда характеризуется высокой динамикой и фрагментированностью, в связи с чем становится всё более актуальной задача анализа реального содержания вакансий и резюме с использованием методов обработки больших данных. Традиционные подходы к исследованию рынка труда, основанные на обобщённой статистике, теряют эффективность, поскольку не учитывают текстовую специфику профессиональных требований, реальную структуру навыков и предпочтений кандидатов. Для достижения поставленной цели необходимо формализовать задачу сопоставления характеристик соискателей и требований работодателей с целью выявления ключевых областей несоответствия.

Аналитическая постановка задачи выпускной квалификационной работы звучит так: выявление степени соответствия между ожиданиями соискателей и требованиями работодателей на рынке труда города Москвы.

В рамках поставленной задачи необходимо определить представления о структуре спроса и предложения труда, опираясь на такие характеристики, как профессиональный опыт, уровень образования, набор профессиональных и универсальных навыков, уровень желаемой или предлагаемой заработной платы, график работы и готовность к мобильности. Далее требуется оценить метрики расхождения, отражающие количественные и содержательные различия между ожиданиями соискателей и предложениями работодателей. Анализ таких расхождений позволит выявить профессиональные группы, в

которых дисбаланс проявляется наиболее остро, а также определить системные проблемы, связанные с профориентацией, кадровым планированием и эффективностью системы профессионального образования.

Ключевая трудность заключается в отсутствии формализованной структуры у большей части информации, содержащейся в вакансиях и резюме. Навыки, должности, описания опыта, образования и ожидания заработной платы представлены в текстовом виде, что требует применения методов обработки естественного языка. Таким образом, задача сопоставления соискателей и вакансий переходит в плоскость машинного обучения: необходимо извлечь признаки из неструктурированных текстов, представить их в векторном виде и рассчитать меру сходства между двумя множествами — множеством вакансий и множеством резюме.

Задача осложняется также наличием пропусков, дубликатов и вариативностью описаний одних и тех же навыков и должностей, что требует предварительной очистки данных, нормализации терминов и приведения к единому формату. Кроме того, в рамках анализа предполагается разработать и использовать метрики, позволяющие количественно оценить несоответствие между спросом и предложением на труд. Такие метрики позволят не только оценить общий уровень несоответствия, но и провести детальный анализ по отдельным профессиональным, возрастным группам, а также уровням образования.

2. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

2.1 Методы анализа несоответствия на рынке труда

Анализ несоответствия на рынке труда осуществляется с использованием широкого спектра статистических и вычислительных методов. Итоговая метрика должна учитывать, как соответствие количественных, так и качественных переменных. С первыми все просто – проводить анализ можно анализируя средние, медианные значения. Для вторых задача усложняется. Их тоже можно интерпретировать как числа, используя модифицированные методы наименьших квадратов, например ОМНК. Однако для наилучших результатов потребуется использовать меры сходства множеств. Также особую трудность представляет анализ текстовых данных. Для них потребуются методы машинного обучения и обработки натурального текста.

Для оценки соответствия зарплатных ожиданий можно использовать метод расчета средней абсолютной ошибки между желаемой и предлагаемой зарплатой по позициям, сгруппированным по профессиям или отраслям. Распределения зарплат анализируются с помощью плотности вероятности и сравниваются с помощью метода Колмогорова-Смирнова [5].

2.1.1 Меры сходства

Методы оценки соответствия множеств применяются в случаях, когда вакансии и резюме описываются в виде наборов признаков, например, навыков, ключевых слов или требований. Мера сходства — это количественная оценка, показывающая, насколько похожи два объекта, вектора, множества или последовательности. Она широко используется в машинном обучении, анализе данных, обработке естественного языка, биоинформатике и других областях.

Существует множество алгоритмов, позволяющих вычислять меру сходства. Их можно разделить на две группы: традиционный поиск и поиск с использованием машинного обучения. Первый часто применяется для

сравнения множеств из заранее известных элементов. Например, с его помощью можно найти соответствие ожиданий навыков работодателя от реально имеющихся данных у соискателей на рынке труда. Методы машинного обучения позволяют находить сходство разнородных текстов за счет их векторизации.

Самый простой в реализации метод – это мера Жаккара, рассчитываемая по формуле ниже (1). Он очень прост и позволяет получить хороший коэффициент сходства для больших множеств за счет нахождения отношения размерности пересечения множеств к размерности их объединения.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (1)$$

Однако мера Жаккара дает не лучшие результаты при анализе сходства небольших множеств. В таком случае хорошим вариантом будет использование меры Сёренсена: она дает больший вес совпадениям множеств. Определяется, как отношение двойного пересечения множеств к сумме их размеров (2).

$$S(A, B) = \frac{2|A \cap B|}{|A| + |B|} \quad (2)$$

Такая мера может быть более полезной при оценке соответствия требуемых технических навыков, так как обучение нового сотрудника используемой на производстве технологии может быть довольно дорогой.

В случае обработки текстовых данных тоже существуют свои традиционные методы нахождения сходства. Среди них двумя самыми популярными можно назвать метод шинглов и алгоритм Ливенштейна [13]. Метод шинглов заключается в разбиении текстов на пересекающиеся подстроки длиной k . Для каждого текста формируется множество таких

шинглов (рис. 2.1), после чего для оценки схожести применяется мера Жаккара между множествами шинглов. Этот метод устойчив к перестановкам слов и синтаксическим вариациям.

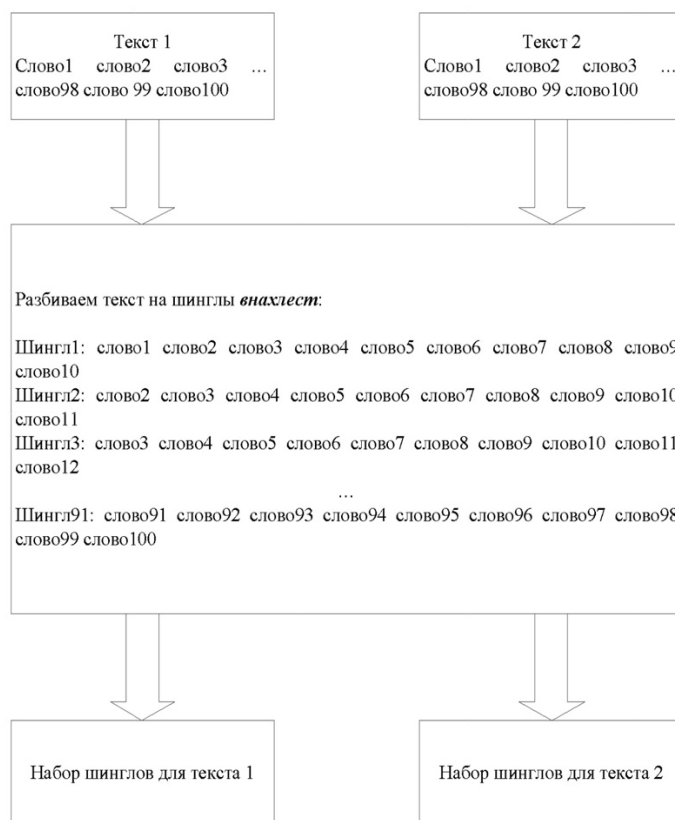


Рисунок 2.1 Выделение шинглов из текста

Алгоритм Левенштейна вычисляет минимальное количество элементарных операций (вставка, удаление, замена символа), необходимых для превращения одной строки в другую [13]. Расстоянием Левенштейна называется сумма всех необходимых перестановок в тексте (рис. 2.2). Он применяется для оценки степени орфографического или структурного сходства текстов, в том числе при сравнении названий профессий, должностей или формулировок обязанностей. Совокупное применение этих методов позволяет строить метрики соответствия между вакансиями и резюме, учитывать как

структурные, так и текстовые признаки, и тем самым глубоко анализировать характер несоответствия на рынке труда.

		Н	У	У	Н	Д	А	И
	0	1	2	3	4	5	6	7
Н	1	0	1	2	3	4	5	6
О	2	1	1	2	3	4	5	6
Н	3	2	2	2	2	3	4	5
Д	4	3	3	3	3	2	3	4
А	5	4	4	4	4	3	2	3

Рисунок 2.2 Матрица расстояний в алгоритме Ливенштейна

2.1.2 Анализ сходства текстов методами машинного обучения

Для анализа текстов необходимо в первую очередь векторизовать их, то есть перевести в численный вид. Это достигается большим количеством разных методов. Одним из самых простых является TF-IDF (англ. term frequency-inverse document frequency). Его суть в том, чтобы предобработанный, лемматизированный и отсортированный словам в тексте присвоить одно число – их частоты встречаемости. Например, из предложения «Машина была красной, было две машины» получится вектор {2, 1, 1, 2}. Однако тут сразу видно проблему алгоритма, ведь существительное в именительном падеже «машина» и притяжательном (чья?) «Машина» будут выделены как одно и то же слово. Важно заметить, что алгоритм TF-IDF отдает векторы без фиксированной длины. Таким образом TF-IDF не учитывает контекст.

Word2Vec решает эти проблемы, обучая плотные векторные представления слов, в которых семантически близкие слова располагаются рядом в векторном пространстве. Это позволяет учитывать контекст и смысловую нагрузку лексем, что особенно важно при анализе текстов, где одинаковая идея может быть выражена разными словами. В отличие от TF-IDF,

Word2Vec позволяет распознавать синонимы и тематическую близость. Кроме того, векторы фиксированной размерности делают анализ более вычислительно эффективным.

Результатом работы обоих алгоритмов является вектор. Для оценки близости векторов удобно использовать метрик. Такими метриками являются косинусное и евклидово расстояния. В зависимости от задачи следует выбрать одно из них. Также эти метрики можно применить и к векторам, в которые преобразуют тексты большие языковые модели.

Современные методы основаны на языковых моделях трансформерного типа, таких как BERT (Bidirectional Encoder Representations from Transformers) [17] и его модификациях: RoBERTa, ALBERT и другие. Эти модели обучаются на задачах маскирования слов и предсказания следующего предложения, что позволяет им обрабатывать сложные контекстные зависимости. Для задач оценки сходства текстов используются модифицированные архитектуры, такие как Sentence-BERT (SBERT), позволяющие получать векторные представления предложений или абзацев. После кодирования двух текстов в такие векторы, между ними вычисляется косинусное расстояние. SBERT демонстрирует высокую точность в задачах семантического сопоставления благодаря своей способности учитывать контекст, грамматическую структуру и смысловую насыщенность.

На схеме ниже показана их общая структура (рис. 2.3). Модель разбита на два главных слоя: embedding и transformer. Первый необходим для того, чтобы векторизовать получаемый текст. После чего итоговое векторное представление обрабатывается нейросетью, состоящую из нескольких слоев контекста [17].




Рисунок 2.3 Структура BERT

Применение указанных методов в анализе соответствия резюме и вакансий позволяет учитывать не только совпадения ключевых слов, но и семантическое соответствие формулировок, контекста и структуры описаний. Это существенно повышает точность автоматических систем сопоставления и рекомендаций на рынке труда, особенно в условиях неоднородного и слабо формализованного текстового материала.

2.1.3 Предобработка текстов для анализа

Любые данные перед анализом методами машинного обучения необходимо нормализовать. В случае обработки текстов требуется привести все формы слов к одной, например к лемме. Для этого используются алгоритмы лемматизации и стемминга. Без нормализации текстовых данных модели могут давать неточный или вовсе неверный ответ.

Стемминг – это алгоритм, отсекающий окончания у слов, таким образом оставляя только корень. Этот подход может не всегда оказываться эффективным, теряя в точности перед аналогом [13]. В отличие от него, лемматизация позволяет провести лингвистический анализ слов, приводя их к лемме, что точно сохраняет их смысл, однако требует дополнительных вычислительных ресурсов за счет необходимости использования языковых моделей. Оба инструмента представлены в библиотеке NLTK.

Таблица 1 – Сравнение лемматизации и стемминга

Критерий	Лемматизация	Стемминг
Точность	Высокая	Низкая
Скорость	Низкая	Высокая
Обработка незнакомых слов	Требует наличия словаря	Возможна алгоритмически
Применение	Обработка больших объемов информации	Точная обработка небольших объемов данных
Пример	Бегущий – бег Кошку – кошк	Бегущий – бежать Кошку - кошка

Таким образом стемминг лучше использовать для быстрой предварительной обработки больших текстовых данных, когда допустима некоторая потеря точности. Лемматизация предпочтительна в задачах, где важны точность и сохранение лингвистических свойств слов, но требует больше вычислительных ресурсов и качественных языковых моделей. В реальных проектах часто применяют комбинацию обоих методов. Важно еще заметить, что для лемматизации требуются наличие специального словаря, который не всегда реализован в рамках библиотек.

2.2 Выбор средств разработки и анализа

При анализе соответствия ожиданий соискателей и требований работодателей на основе больших данных наиболее подходящим языком программирования является Python. Он обладает более широкой экосистемой

библиотек для работы с текстами, машинного обучения и глубокого обучения по сравнению с R. Python активно используется в индустрии и академической среде, а также поддерживает современные подходы на основе нейросетей, в частности трансформеры и эмбединги. Это особенно важно при анализе текстовых данных, таких как описание вакансий и резюме, где требуется работа с языковыми моделями. Не менее важно также и глубокая интеграция библиотек Python с внешними системами, возможность реализации обращения к моделям по HTTP, пакетный менеджер PIP и возможность использования Jupyter Notebook.

Jupyter Notebook – это интерактивная среда программирования, в которой код, визуализации и текстовые комментарии объединены в единый документ. Она идеально подходит для задач разведочного анализа (EDA), тестирования гипотез, построения графиков.

Основной инструментарий Python для анализа включает библиотеки `pandas` и `numpy` для работы с табличными и числовыми данными. `Pandas` удобен для подготовки данных, фильтрации, агрегации, обработки пропущенных значений и трансформаций. Он позволяет эффективно работать с большими наборами резюме и вакансий, выполнять группировки, сводные таблицы, объединения и многое другое. `NumPy` необходим для базовой работы с массивами и матрицами, и часто используется вместе с `pandas`, особенно на этапе преобразования данных к числовому виду. Однако для более эффективного анализа данных необходимо оптимизировать и механизм работы с ними. Было решено перевести имеющиеся данные в формат `parquet`.

Формат `Parquet` — это колонко-ориентированное хранилище данных, разработанное для эффективной работы с большими объёмами информации. В отличие от классических текстовых форматов вроде `CSV` или `JSON`, `Parquet` сохраняет данные в сжатом виде и позволяет читать только необходимые

столбцы. Это критично, если вы работаете с десятками или сотнями гигабайт (изначальная таблица для анализа соответствия ожиданий соискателей и требований работодателей имеет размер в 26Гб). Благодаря колонковой структуре и встроенному сжатию, Parquet позволяет значительно экономить как место на диске, так и время чтения/загрузки.

Для работы с текстом применяются библиотеки NLTK и spaCy. NLTK полезен для базовой обработки текста: токенизация, стемминг, лемматизация. Однако spaCy более производительный и ориентирован на промышленное применение, поддерживает различные языковые модели, умеет извлекать сущности, зависимости и выполнять лемматизацию. Но для продвинутого анализа текстов, особенно в задаче сопоставления вакансий и резюме, где важен смысл, а не только структура, их возможностей недостаточно.

Для векторизации и токенизации данных необходимо использовать библиотеки для работы с нейросетями и трансформерами. HuggingFace Transformers — это ведущий фреймворк, предоставляющий доступ к предобученным языковым моделям, таким как BERT, RoBERTa, DistilBERT и SBERT. Эти модели можно использовать для получения векторов резюме и вакансий, после чего сравнивать их с помощью косинусного расстояния или кластеризовать. Библиотека sentence-transformers строится на HuggingFace и предоставляет простой интерфейс для получения векторов из языковых моделей. Это делает её особенно удобной для задач кластеризации или поиска похожих текстов.

Для кластеризации хорошо подходят scikit-learn и faiss. Scikit-learn предоставляет широкий набор алгоритмов машинного обучения, включая KNN, DBSCAN, агломеративную кластеризацию и методы снижения размерности, такие как PCA и t-SNE. Faiss от Facebook эффективен для поиска ближайших соседей в высокоразмерных пространствах, что важно при работе

с эмбедами. Это позволяет эффективно сопоставлять множество вакансий и резюме и находить наиболее близкие пары по смыслу.

Таким образом, Python с его обширной экосистемой библиотек предоставляет все необходимые инструменты для анализа текстовых данных, включая предобработку, визуализацию, извлечение признаков, обучение моделей и интерпретацию результатов. Он значительно превосходит R по гибкости, поддержке современных NLP-подходов и совместимости с нейросетевыми архитектурами.

2.3 Математическая постановка задачи анализа соответствия ожиданий соискателей и требований работодателей на основе больших данных

Математическая постановка задачи анализа соответствия ожиданий соискателей и требований работодателей на основе больших данных может быть представлена как задачу сопоставления целевых параметров с целью минимизации или максимизации некоторой функции соответствия между двумя множествами: резюме и вакансиями.

Пусть $R = \{ r_1, r_2, \dots, r_N \}$ – множество резюме соискателей, где N — количество резюме.

Пусть $V = \{ v_1, v_2, \dots, v_M \}$ – множество вакансий, где M — количество вакансий.

Для каждого резюме $r_i \in R$ и вакансии $v_j \in V$ определены наборы признаков, которые включают как количественные, так и качественные параметры:

X^{r_i} – вектор признаков для резюме (опыт работы, образование, навыки, ожидаемая зарплата, место проживания и другие).

X^{v_j} – вектор признаков для вакансии (требуемый опыт, требования к навыкам, минимальная зарплата, тип работы и другие).

Каждое резюме и вакансия также имеют текстовые описания, для которых могут быть вычислены векторы с использованием моделей глубокого машинного обучения.

$F(r, v)$ – функция соответствия между резюме и вакансией в отдельной профессиональной сфере. Эта функция составлена из нескольких компонент:

$$\mathcal{F}(r, v) = \alpha_1 S(r, v) + \alpha_2 C(r, v) + \alpha_3 L(r, v) \quad (3),$$

Где:

$\alpha_1, \alpha_2, \alpha_3$ – некоторые коэффициенты, обозначающие вклад компоненты

S – функция оценки соответствия количественных признаков

C – функция соответствия качественных признаков

L – функция соответствия описаний на основе машинного обучения

r – массив резюме в выбранной сфере

v – массив вакансий в выбранной сфере

На основе полученной функции можно построить матрицу средних соответствий резюме и вакансий по отраслям, профессиям и демографическим признакам, а также проанализировать распределение этих соответствий.

3. ПРАКТИЧЕСКАЯ ЧАСТЬ

3.1 Предобработка данных

Предобработка данных является важнейшим этапом в любом исследовании, основанном на анализе больших массивов информации, включая анализ рынка труда. Без тщательной предобработки невозможно обеспечить корректность, сопоставимость и интерпретируемость данных, что особенно критично при анализе вакансий и резюме, представленных в разнородных форматах и с высоким уровнем синтаксического и семантического шума.

Основная цель предобработки — устранение искажений, дубликатов, пропусков, ошибок ввода и других артефактов, которые могут существенно исказить результаты анализа. Например, пропуски в данных о возрасте или неправильное их заполнение, некорректные данные в столбцах, отсутствие лемматизации текстов могут привести к ошибочному отнесению записей к разным кластерам при использовании методов машинного обучения. Отсутствие предобработки данных может привести к множеству негативных последствий: снижению точности классификации, ложным выводам при анализе несоответствий между ожиданиями соискателей и требованиями работодателей, некорректной визуализации, а также невозможности построения надежных метрик сходства между вакансиями и резюме.

В рамках анализа рынка труда предобработка включает в себя, в частности, лемматизацию и токенизацию текстов, нормализацию записей (например, приведение всех символов к нижнему регистру), устранение стоп-слов, а также синтаксическое сглаживание. Помимо этого, важным этапом является кодирование признаков: для категориальных переменных используется кодирование (например, с помощью ОМНК), для текстов —

векторные представления, такие как TF-IDF, Word2Vec или BERT, позволяющие измерять семантическую близость между записями.

Для реализации всего вышеописанного было решено использовать Python. Этот инструмент имеет огромные возможности для предобработки и анализа данных. В нем широко используются специализированные библиотеки, например: `pandas` — для обработки табличных данных, `nltk` — для обработки естественного языка, `scikit-learn` — для трансформации признаков и реализации моделей машинного обучения, `gensim` — для тематического моделирования и работы с векторными представлениями слов, `re` — для регулярных выражений при очистке текста. При необходимости более глубокой семантической обработки применяются большие языковые модели, такие как BERT. Работу с ними сильно упрощает библиотека `transformers`.

Имеющиеся в распоряжении данные содержат значительное количество пропусков и недостоверных значений, что делает невозможным их непосредственное использование для анализа. Отсутствие информации по ключевым признакам, таким как заработная плата, опыт работы, уровень образования или набор требуемых навыков, затрудняет построение корректных моделей и ведёт к искажению выводов. Кроме того, в массиве наблюдаются случаи логических несоответствий, некорректного формата дат, дублирования записей и неправдоподобных значений, что указывает на необходимость обязательной процедуры очистки данных перед началом аналитической обработки. В ходе предобработки данных в исходном наборе с резюме осталось 336 865 строк (рис. 3.1), а в наборе с вакансиями – 19 106 (рис. 3.2).

candidateId	birthday	gender	age	positionName	typicalPosition	publishedDate	skills	worldskillsInspectionStatus	abilympicsInspectionStatus	abilympicsParticipation	...
f6fbcb170-a190-11e6-841a-ef76bd2a03c1	1989-05-25 20:00:00+00:00	женск	35.0	архивариус, делопроизводитель.	None	2016-11-22 17:10:01+03:00	[]	False	False	False	...
27700f90-7643-11e5-8f00-833b590698f7	1992-08-01 20:00:00+00:00	женск	32.0	инженер	None	2015-10-20 09:47:57+03:00	[]	False	False	False	...
eb785b50-9dbe-11e7-9620-4376a32b3f45	1976-09-28 21:00:00+00:00	мужск	48.0	сотрудник в офис	None	2017-09-20 09:56:06+03:00	[]	False	False	False	...
742bf9a0-9d06-11e6-b6d2-e73e8fa159bf	2002-08-27 20:00:00+00:00	мужск	22.0	младш инженер разработчик	None	2024-02-08 12:25:36+03:00	[]	False	False	False	...
c672ef90-74c3-11e6-804e-e73e8fa159bf	1987-07-17 12:00:00+00:00	женск	37.0	смен мастер	None	2023-10-30 08:05:32+03:00	[]	False	False	False	...
...	...	...	...	...	...	...	...	...	...	...	...
27543690-65f7-11e6-b69f-b905bef6f6f7a	1991-07-16 12:00:00+00:00	женск	33.0	экономист в банк	None	2021-02-03 11:37:26+03:00	[]	False	False	False	...
a5bb7f80-1f3d-11f0-8eb0-03e6ffa13304	1985-01-17 12:00:00+00:00	женск	40.0	бухгалтер	бухгалтер	2025-04-22 11:32:17+03:00	["Работать с программой 1С", "Знание офисных п...	False	False	False	...
0ec7e980-1f7e-11f0-a82c-a78d29e6ed87	1976-04-20 12:00:00+00:00	женск	49.0	главн специалист по охран окружа сред	специалист по охран окружа сред (эколог)	2025-04-22 17:03:01+03:00	["Навыки межличностного общения", "Умение рабо...	False	False	False	...
b31c2db0-1ece-11f0-a3e6-4db136472102	1967-12-03 12:00:00+00:00	женск	57.0	врач ледиатр	нич не выбра	2025-04-22 08:43:35+03:00	[]	False	False	False	...
09e77980-f10a-11e5-8918-4376a32b3f45	1983-09-13 12:00:00+00:00	мужск	41.0	руководител проект	руководител проект	2025-04-22 08:45:37+03:00	["Управление, руководство коллективом, командо...	False	False	False	...
336865 rows x 31 columns											

Рисунок 3.1 Подготовленный набор данных с резюме

id	codeProfession	codeProfessionalSphere	socialProtecteds	languageKnowledge	busyType	educationRequirements	hardSkills	softSkills	skills	typicalPosition	...	qualifications
1bdfbcb0-f9b1-11ef-9ae2-25abf1fceb2	NaN	sales	None		None	{"educationType": "Не указано"}	[]	[]	[]	None	...	None
464a0d88-c5b7-11ef-96cd-29eee581bb17	209204.0	informationtechnology	None		полная занят	{"educationType": "Высшее-специалитет, магистр..."}	[]	[]	[]	ничего не выбра	...	высшее техническое образование, опыт работы с ...
23e60dd5-b130-11ee-9b60-cb26dff57dd7	277409.0	accountingtaxesmanagement	None		полная занят	{"educationType": "Высшее-бакалавриат", "educat..."}	[]	[]	[]	None	...	внутренние организационные распорядительные докум...
1f58a7f8-ddf3-11ef-9bbd-d549be31d974	208894.0	informationtechnology	None		полная занят	{"educationType": "Высшее-специалитет, магистр..."}	[]	[]	[]	ничего не выбра	...	высшее образование, опыт работы не менее 3 лет5
4bc2c13a-17e9-11ef-9741-e7d0d2cf29b1	204484.0	medicine	None		полная занят	{"educationType": "Высшее-специалитет, магистр..."}	[]	["Подбор очков", "Подбор линз"]	офтальмолог	врач	...	работа на авторефрактометре, умение подбирать ...
...	...	...	...	...	...	...	...	...	...	...	...	...
fec75f38-1b83-11f0-b4c1-e7d0d2cf29b1	224469.0	industry	инвалид		None	{"educationType": "Высшее-бакалавриат"}	[]	[]	[]	инженер технолог	...	высшее (техническое) специальное по образова...
fe842648-1f55-11f0-9de6-d549be31d974	277288.0	accountingtaxesmanagement	None		полная занят	{"educationType": "Высшее-бакалавриат"}	[]	[]	[]	ничего не выбра	...	высшее профессиональное образование аналогичны...
fdffa592-3f22-11ed-a739-dbfed3997e57	NaN	workingspecialties	None		None	{"educationType": "Не указано"}	[]	[]	[]	None	...	None
fde4a475-f166-11ec-ba26-550ed7335bbe	123978.0	industry	None		полная занят	{"educationType": "Не указано"}	[]	[]	[]	None	...	опыт работы на производстве от 0,5 года, в ана...
fd97dc8-009d-11f0-bdbcb26dff57dd7	166719.0	bulldindrealty	None		времен	{"educationType": "Среднее профессиональное"}	[]	[]	[]	ничего не выбра	...	знание способов устройства каркасов стен, чист...
19106 rows x 44 columns												

Рисунок 3.2 Подготовленный набор данных с вакансиями

3.2 Разведочный анализ данных

Разведочный анализ данных представляет собой первичный этап аналитической работы, направленный на получение общего представления о

структуре, характеристиках и взаимосвязях внутри данных. Его главная цель — выявить основные закономерности, аномалии, выбросы, пробелы и скрытые зависимости в данных, а также проверить корректность их предварительной обработки. В контексте анализа московского рынка труда этот этап позволяет на сразу определить, насколько репрезентативны имеющиеся данные о вакансиях и резюме, установить частотное распределение ключевых признаков (например, навыков, зарплатных ожиданий, уровня образования), а также оценить целесообразность применения тех или иных моделей сопоставления.

Разведочный анализ данных позволяет сформулировать гипотезы для последующего статистического тестирования, выявить возможные проблемы согласования форматов данных между различными источниками и выбрать релевантные метрики для количественной оценки несоответствий.

На таблицах ниже представлены общие метрики о количественных факторах в выбранных наборах данных. Также данные сразу были проверены на нормальность

Таблица 2

Количественные данные в наборе с резюме

	Возраст, лет	Опыт, лет	Зарплата, руб.
Мода	36,0	0,0	50000,0
Среднее	41,1	7,3	74608,0
Стандартное отклонение	11,3	13,1	59369,8
Минимум	15,0	0,0	20002,0
25%	33,0	1,0	45000,0
50%	40,0	5,0	60000,0
75%	50,0	11,0	80000,0
Максимум	88,0	59,0	1000000,0

Таблица 3

Количественные данные в наборе с вакансиями

	Опыт	Кол-во рабочих мест	Зарплата от, руб.	Зарплата до, руб.	Испытательный срок
Количество	18274,0	19106,0	18218,0	15510,0	19106,0
Среднее	1,3	3,3	64153,3	81724,7	0,0
Стандартное отклонение	1,9	21,9	42436,0	54170,9	1,9
Минимум	0,0	1,0	0,0	0,0	0,0
25%	0,0	1,0	35000,0	55000,0	0,0
50%	0,0	1,0	59000,0	75735,0	0,0
75%	3,0	1,0	80000,0	100000,0	0,0
Максимум	30,0	1300,0	800000,0	1000000,0	165,0

Важно также заметить, что работодатели заполняют не все данные или делают это без должной ответственности. Из-за этого много строк пропущена или содержит недействительные данные. Например, в некоторых вхождениях проставлена отрицательная зарплата или опыт работы. Также существует практика, по которой заводится вакансия только на одного кандидата, хотя по ней набирают множество специалистов.

3.2.2 Социально-демографические зависимости в наборе данных резюме

Социально-демографические характеристики играют ключевую роль в анализе процессов, происходящих на рынке труда, так как именно они формируют контекст, в рамках которого осуществляется занятость населения [8]. Возраст, пол, уровень образования, профессиональный опыт, семейное положение, миграционный статус и иные параметры соискателей и работников

существенно влияют как на структуру предложения рабочей силы, так и на её качество.

Анализ социально-демографических характеристик позволяет выявить не только текущую ситуацию в части занятости различных категорий населения, но и спрогнозировать изменения, которые могут возникнуть под влиянием демографических и социальных процессов. Например, старение населения, сокращение доли молодежи, изменение образовательной структуры, рост внутренней миграции формируют новые вызовы для работодателей и требуют адаптации со стороны системы профессионального образования. Кроме того, социально-демографические данные позволяют оценить неравномерность распределения трудовых ресурсов по профессиональным, территориальным и возрастным группам, что необходимо для выявления и устранения структурных диспропорций на рынке труда.

Распределение соискателей по возрасту и опытно-возрастная структура являются ключевыми элементами при анализе состояния и динамики рынка труда. Они позволяют понять, каков реальный состав рабочей силы, выявить его демографические особенности и оценить потенциальные риски и дефициты кадров в различных возрастных группах. Возраст соискателя отражает стадию его профессиональной карьеры и жизненного цикла, что оказывает непосредственное влияние на его профессиональные амбиции, предпочтения в сфере занятости, готовность к переобучению, мобильность и гибкость в выборе профессиональных направлений. Молодые соискатели, как правило, обладают относительно небольшим профессиональным опытом, однако часто демонстрируют высокую адаптивность, готовность к освоению новых навыков и более широкие ожидания по поводу профессиональной реализации. Напротив, старшие возрастные группы характеризуются значительным профессиональным стажем, но вместе с тем могут обладать ограниченной

мобильностью и меньшей гибкостью в освоении новых технологий и профессий.




Рисунок 3.3 Распределение опыта работы и возраста соискателей

Диаграмма (рис. 3.3), позволяет визуальнo отразить взаимосвязь возраста и профессионального опыта соискателей. На ней чётко прослеживается естественная зависимость между возрастом и накопленным трудовым стажем: по мере увеличения возраста растёт и опыт работы. Вместе с тем выявляется зона концентрации соискателей в интервале от 20 до 40 лет с опытом до 10–15 лет, что соответствует наиболее активной фазе профессиональной деятельности.

Значительное число соискателей с маленьким или нулевым опытом работы в сфере может говорить о большем числе выпускников или людей, меняющих профессию. В свою очередь, меньшая численность пожилых соискателей с большим опытом может свидетельствовать о частичном выходе

данной группы из активной профессиональной деятельности, что в дальнейшем способно усилить дефицит квалифицированных кадров в высококвалифицированных и руководящих сегментах рынка труда. уровня.




Рисунок 3.4 Распределение возраста соискателей по уровню образования

На диаграмме (рис. 3.4) представлено распределение возраста соискателей по уровню образования. На ней четко видно, что средний возраст людей с основным общим образованием меньше 25. Это может говорить о том, что молодые люди в Москве часто выбирают получение высшего образования вместо работы сразу после школьного. Также заметно то, что большая часть соискателей со средним профессиональным образованием находится между 30

и 55 годами, что подтверждает ориентированность столицы на высококвалифицированный труд [8].

Также важно учитывать, что образовательный уровень тесно связан с зарплатными ожиданиями соискателей и влияет на их мобильность, готовность к переобучению и способности адаптироваться к быстро меняющимся требованиям рынка труда [4]. Соискатели с высоким уровнем образования чаще ориентированы на позиции с перспективой карьерного роста, в то время как соискатели со средним образованием могут проявлять большую гибкость в отношении условий труда.




Рисунок 3.5 Распределение образования по полу

Также интерес может представлять распределение образования по полу. Это особенно важно в условиях перекоса количества соискателей в сторону

женщин. На диаграмме ниже (рис. 3.5) представлена гистограмма по полу и образованию.

Исходя из данных, женщины на рынке труда чаще являются соискателями с высоким уровнем образования. Учитывая это и то, что женщина на рынке труда больше, можно сказать что они чаще вовлечены в высококвалифицированный труд, чем мужчины.

3.2.3 Зависимости в данных по вакансиям

Анализ распределения вакансий по профессиональным сферам позволяет выявить структуру спроса на рынке труда и определить, в каких отраслях работодатели испытывают наибольшую потребность в кадрах. Такое распределение отражает актуальные экономические и структурные приоритеты, а также уровень активности различных секторов экономики. Гистограмма, построенная на основе группировки по признаку профессиональной сферы, даёт возможность оценить относительный вес каждой категории в общем объёме вакансий, выявить доминирующие направления и определить потенциальные зоны кадрового дефицита. Данный визуальный инструмент является важным элементом разведочного анализа, формирующим основу для последующего сопоставления с данными о соискателях и для выявления структурных диспропорций между спросом и предложением на рынке труда.

На диаграмме ниже (рис. 3.6) представлены 20 самых популярных сфер на московском рынке труда.




Рисунок 3.6 Распределение вакансий по профессиональным сферам

Эта диаграмма подкрепляет информацию о том, что москва отличается от России в целом по востребованности на рынке труда [8]. В первую очередь в столице востребованы продажи и цифровые технологии, а также прочие рынки услуг. Такие профессиональные сферы в целом соответствуют высокому уровню образования у соискателей.




Рисунок 3.7 Зависимость зарплаты от требуемого опыта работы

Распределение предлагаемой заработной платы по требуемому опыту работы (рис. 3.7) отражает логику формирования рыночной стоимости труда и ожидания работодателей относительно квалификации кандидатов. Вакансии, рассчитанные на соискателей с минимальным или нулевым опытом, как правило, сопровождаются более низкими уровнями оплаты, что обусловлено необходимостью последующего обучения и адаптации таких работников. С увеличением стажа работодатели готовы предлагать более высокие зарплаты, так как предполагается наличие у кандидатов профессиональных навыков, самостоятельности, управленческого потенциала и способности к принятию решений. Наибольший рост заработной платы обычно наблюдается в переходе от начальных категорий к опыту свыше трёх лет, после чего темп прироста может замедляться или стабилизироваться, особенно в отраслях с фиксированными тарифами или ограничениями бюджета. Анализ вакансий по этой зависимости позволяет выявить средние рыночные ориентиры и границы

квалификационных ожиданий, а также определить профессии и сферы, в которых опыт наиболее существенно влияет на уровень оплаты труда.

Однако на диаграмме (рис. 12) четко не прослеживается рост зарплаты от опыта работы. Ставится гипотеза о независимости этих факторов, которая будет исследована в следующем разделе.

3.3 Реализация метрики соответствия спроса и предложения на рынке труда в Москве

В этой части работы рассматривается практическая реализация метрики, предназначенной для количественной оценки степени соответствия между спросом работодателей и предложением со стороны соискателей на рынке труда Москвы. На основе предварительно обработанных данных о вакансиях и резюме осуществляется построение векторных представлений ключевых характеристик (навыков, опыта работы, уровня образования, зарплатных ожиданий), с последующим применением методов измерения сходства между соответствующими множествами признаков. Целью разработки метрики является выявление областей наибольшего несоответствия и формализация различий между требованиями работодателей и профилями кандидатов, что служит основой для последующего анализа структурных дисбалансов и выработки рекомендаций для участников рынка труда.

В обоих наборах данных есть общие атрибуты. Проще всего будет начать оценку с них. Далее последует новый этап работы: выявление признаков в текстах с помощью методов обработки натурального языка. Все тексты уже были предварительно лемматизированы с помощью библиотеки nltk.

Функция соответствия между резюме и вакансией состоит из трех компонент: функции соответствия количественных, качественных и текстовых факторов. Выведем каждую из них по порядку.

3.3.1 Функция соответствия количественных факторов

Для количественной оценки степени соответствия между распределениями признаков спроса и предложения на рынке труда целесообразно использовать формализованную функцию соответствия, основанную на сравнении распределений. В качестве инструмента для такой оценки выбран тест Колмогорова–Смирнова, который позволяет измерить максимальное отклонение распределения двух независимых выборок. Применение данного подхода к анализу таких количественных факторов, как зарплатные ожидания, стаж работы или возраст кандидатов, позволяет объективно зафиксировать степень расхождения между предпочтениями соискателей и требованиями работодателей, тем самым обеспечивая основу для построения интегральной метрики несоответствия (Приложение А).

Также этот тест удобно использовать по следующим причинам: он не требует нормальности распределения выборки и его область значений находится между 0 и 1.

Ниже представлена диаграмма (рис. 3.8) распределения зарплатных ожиданий и предложений на рынке труда в Москве в сфере информационных технологий. Для данной сферы трудового рынка тест Колмогорова-Смирнова возвращает значение 0,1644, что при уровне значимости 0,05 означает, что ожидания соискателей не соответствуют предложению работодателей.




Рисунок 3.8 Сравнение распределения зарплат в сфере ИТ в Москве

Четко видно, что распределение зарплат в вакансиях и резюме не соответствуют друг другу в сферах. Средние и модальные значения в вакансиях ниже, чем в резюме. Это может говорить о востребованности более квалифицированных кадров на рынке труда в сфере информационных технологий.

Для более наглядного представления результатов подобного анализа на уровне различных профессиональных сфер целесообразно использовать тепловую карту. На диаграмме (рис. 3.9) ниже ячейки заполняются значениями D-статистики, полученными при сравнении соответствующих распределений. Такая тепловая карта позволяет выявить сферы с наибольшим структурным дисбалансом по ключевым параметрам и тем самым служит инструментом выявления критических зон несоответствия на рынке труда Москвы.




Рисунок 3.9 Метрика несоответствия по зарплате и опыту по сферам

Анализ результатов демонстрирует, что на рынке труда Москвы степень несоответствия между предложением и спросом по показателю профессионального опыта выражена значительно сильнее, чем по уровню заработной платы. Особенно заметные отклонения зафиксированы в таких сферах, как «Без квалификации», «Домашний персонал» и «Продажи», что,

вероятно, обусловлено высокой неоднородностью внутри этих категорий, включающих широкий спектр должностей с различными требованиями. В отношении заработных ожиданий наиболее существенное расхождение между вакансиями и резюме наблюдается в сферах спорта, государственной службы и металлургии. В совокупности количественные показатели подтверждают, что именно опыт работы остается более несоответствующим фактором, чем уровень зарплаты. Данный вывод согласуется с результатами исследований РАНХиГС, в которых подчеркивается тенденция к завышению требований к опыту со стороны работодателей на современном рынке труда [4].

3.3.2 Функция соответствия качественных факторов

Категориальные признаки представляют собой качественные характеристики объектов наблюдения, принимающие ограниченное число дискретных значений и не обладающие числовой природой. В контексте анализа вакансий и резюме на рынке труда категориальные переменные отражают такие важные свойства, как уровень образования, график работы, тип занятости, профессиональная сфера, пол, готовность к переезду и прочие неметрические параметры. Их корректная обработка имеет решающее значение для построения аналитических моделей, поскольку такие признаки требуют особого подхода к кодированию, визуализации и интерпретации (Приложение Б).

Целью функции категориальных факторов в работе является оценка структуры и различий в качественных характеристиках исследуемых объектов, а также выявить скрытые зависимости и закономерности между различными группами данных. В условиях исследования рынка труда категоризация позволяет адекватно представить и сравнить такие аспекты, как различия в зарплатных предложениях между уровнями образования, графиками работы

или профессиональными направлениями, а также использовать эти параметры как базу для построения моделей сопоставления вакансий и резюме.

В качестве функции оценки категориальных факторов было решено использовать меру Серенсена. Она позволяет более качественно оценить категориальные факторы в исследуемой выборке. Также удобно, что ее область значений соответствует интервалу от 0 до 1. Однако стоит заметить, что в целях одинаковой интерпретации метрик, требуется взять обратную величину от меры Серенсена. Итоговая тепловая карта выглядит следующим образом:




Рисунок 3.10 Тепловая карта по категориальным признакам

На тепловой карте соответствия между характеристиками вакансий и резюме (рис. 3.10) особенно отчетливо проявляется разрыв по признаку гибких навыков в сфере металлургии. Данный разрыв обусловлен отсутствием информации в резюме соискателей, относящихся к данной отрасли, несмотря на то, что работодатели активно указывают соответствующие требования в описаниях вакансий. Это приводит к полной асимметрии между спросом и предложением в части личностных и коммуникативных характеристик, которые, несмотря на свою неформальную природу, играют важную роль в современных трудовых отношениях, особенно в условиях автоматизации и межфункционального взаимодействия.

Кроме того, на карте выделяется столбец, отражающий график работы. В данном случае наблюдается полное соответствие между резюме и вакансиями, что может свидетельствовать о том, что соискатели достаточно чётко обозначают свои предпочтения по типу занятости, а работодатели формируют предложения, соответствующие этим ожиданиям. Вероятно, график работы является одним из немногих признаков, по которым стороны рынка труда действительно демонстрируют согласованность, что может быть связано с более высокой стандартизацией форматов занятости (например, сменный график, гибкий график, пятидневная неделя и т.д.), а также с тем, что эта информация присутствует в обеих сторонах набора данных в чёткой структурированной форме.

Таким образом, наблюдаемая на карте диспропорция по soft skills и одновременное соответствие по графику работы указывают на неравномерную структурированность информации в резюме и вакансиях. Это может быть следствием как технологических ограничений при сборе и обработке данных, так и различий в мотивации сторон: работодатели стремятся чётко формулировать ожидания, в то время как соискатели фокусируются лишь на

базовых, легко формализуемых параметрах. Выявление таких зон структурного расхождения и соответствия играет важную роль для дальнейшей корректировки алгоритмов сопоставления, а также может служить ориентиром для повышения качества профориентационной поддержки и карьерного консультирования.

3.3.3 Функция соответствия текстовых факторов

Функция несоответствия текстовых данных на основе SBERT и косинусной схожести предназначена для количественного определения уровня совпадения смысловых характеристик двух текстов. Она принимает на вход два текстовых фрагмента — например, список навыков из резюме и требования вакансии — и преобразует их в векторные представления с помощью модели Sentence-BERT. Такое представление отражает не только текстовую форму фраз, но и их семантический смысл в многомерном пространстве. Затем с помощью косинусной схожести рассчитывается угол между векторами, что позволяет получить значение из диапазона от -1 до 1, где более близкие к 1 значения указывают на сильное соответствие между текстами. В реализованной метрике было принято использовать обратное значение для консистентности значений метрик (Приложение В).

Результатом работы функции является численная оценка степени соответствия, которую удобно интерпретировать в виде процентного или дробного коэффициента семантического сходства. Это особенно ценно при анализе вакансий и резюме, где ключевые навыки, описания и должностные требования часто формулируются по-разному, даже если их смысл совпадает. Использование SBERT позволяет преодолеть ограничения обычных текстовых сравнений по строкам или по ключевым словам, благодаря обучению на больших массивов фраз и параллелей в разных задачах сопоставления предложений.




Рисунок 3.11 Итоговая тепловая карта по всем исследуемым признакам

Наконец, важно отметить, что значение косинусной схожести требует дальнейшей интерпретации с учётом контекста: для некоторых систем достаточно пороговой оценки (например, ≥ 0.7), а в других случаях нужны дополнительные логические проверки и уточнения. Однако в любом случае использование SBERT и косинусного сравнения превращает анализ текстов из субъективной задачи в воспроизводимый количественный инструмент, что имеет важное значение для фундаментальности и надёжности аналитических

выводов в работе. Использование коэффициентов α_3 из формулы (3) может помочь точнее настроить необходимые параметры.

На диаграмме (рис. 3.11) представлены итоговые компоненты метрики несоответствия. Следует отметить, что значения 0 и 1 могут возникать не в силу идеального совпадения или полного расхождения, а из-за недостаточности данных. К примеру, если отсутствуют описания вакансий или сведения о квалификации соискателей, функция может возвращать крайние значения, что отражает именно ограниченность исходных данных, а не семантическое соответствие.

3.4 Полученные результаты

В ходе работы была разработана итоговая метрика несоответствия между требованиями работодателей и характеристиками соискателей, которая представлена в виде взвешенной суммы трёх компонент. Каждая компонента отражает отдельный аспект соответствия: семантическое совпадение по содержанию текстов вакансий и резюме, уровень квалификации и полноту совпадения ключевых навыков. Такой подход позволяет учитывать не только количественные, но и качественные различия между ожиданиями и возможностями участников рынка труда.

В рамках работы в качестве параметров весов для компонентов были выбраны равные значения $\alpha_1 = \alpha_2 = \alpha_3 = 1/3$. Это решение обеспечивает сбалансированное влияние каждого аспекта на итоговую оценку и исключает доминирование одной компоненты над остальными. Такой выбор был обусловлен как эмпирическими наблюдениями, так и стремлением получить более универсальную метрику, пригодную для анализа различных сегментов рынка труда без необходимости дополнительной перенастройки весов.




Рисунок 3.12 Метрика несоответствия на рынке труда по сферам

На диаграмме (рис. 3.12) представлена итоговая метрика несоответствия по сферам (чем меньше значение, тем выше совпадение ожиданий и предложений). Следует учитывать, что при высоких значениях метрики расхождение не всегда отражает реальную проблему — оно может быть вызвано ошибками или неполнотами в исходных данных, такими как отсутствие описания навыков или некорректная структура текстов.

Справа от каждого столбца указано двустороннее p-значение метрики для соответствующей сферы. У некоторых (например, металлургии и сельского хозяйства) оно очень высокое. При отбрасывании статистически незначимых результатов ($\alpha = 0,05$) получается обновлённая диаграмма ниже (рис. 3.13).




Рисунок 3.13 Статистически значимые значения метрики несоответствия

Итоги работы позволяют сделать вывод о том, что предложенная метрика показывает не только общее соответствие, но и выявляет конкретные зоны несоответствия, требующие внимания. Возможность гибкой настройки весов обеспечивает адаптацию метода под разные задачи — например, акцентируя внимание на опыте или навыках. Применение метода на практике способно стать основой для инструментов автоматизированного подбора персонала, анализа пробелов в профподготовке и разработки мер по согласованию образовательных программ с реальными требованиями работодателей.

ЗАКЛЮЧЕНИЕ

Основной задачей стало выявление характерных несоответствий между ключевыми навыками и компетенциями, представленных в резюме, и требованиями, зафиксированными в описаниях вакансий. Анализ опирался на два больших набора данных: один массив с резюме, отражающее запросы и предпочтения соискателей, и второе — массив вакансий, иллюстрирующий требования работодателей.

В ходе исследования был выполнен частотный анализ терминов, связанных с профессиональными навыками, которые фигурировали в обоих наборах данных. Это позволило установить характер расхождений между гибкими и жесткими, а также понять, какие компетенции оказались недооценёнными соискателями по сравнению с ожиданиями работодателей. Анализ выявил, что соискатели чаще выделяют универсальные качества, в то время как работодатели делают акцент на технических навыках и специализации.

Для структурирования и сопоставления тематических направлений использовалась векторизация вакансий и резюме с помощью методов машинного обучения и обработки естественного языка. Результатом стало выделение крупных тематических групп, таких как IT, маркетинг и управление проектами, а также выявление областей с наиболее значительным расхождением — металлургия, сельское хозяйство, управление. Эти результаты указывают на степень подготовленности кандидатов к узконаправленной специализации.

Анализ также включал визуализацию результатов — тепловые карты пересечений терминов, графы взаимосвязей навыков и временные диаграммы. Это позволило представить аудитории наглядные подтверждения выявленных

закономерностей, облегчило интерпретацию сложных зависимостей и обеспечило более глубокое понимание исследуемых процессов.

При этом было учтено ограничение выборки: анализ затрагивал только вакансии и резюме, опубликованные в интернет-ресурсах, и охватывал лишь период до мая 2025 года. Это накладывает ограничения на обобщение выводов на весь московский рынок труда, особенно в сегменте прямых контактов или закрытых размещений. Тем не менее методологическая база, отлаженная в ходе работы, хорошо масштабируется и может быть применена к расширенным наборам данным и другим регионам.

Таким образом, расширенное аналитическое описание продемонстрировало, что применённый комплексный подход — от лингвистической предобработки до статистического и тематического анализа — позволяет эффективно анализировать большие объёмы данных, выявлять характерные разрывы в рынке труда и описывать их с научной точностью. Это создаёт прочную основу для последующих исследований в области трудовой аналитики с использованием больших данных и машинного обучения.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ И ЛИТЕРАТУРЫ

1. Васильева О.О., Абабкова М.Ю. КАРЬЕРНЫЕ ОЖИДАНИЯ СТУДЕНТОВ ГУМАНИТАРНЫХ СПЕЦИАЛЬНОСТЕЙ НА РЫНКЕ ТРУДА // Вестник Алтайской академии экономики и права. 2024. № №1 2024. С. 17–23.
2. Глоссарий ProactionPro Рынок труда // Рынок труда [Электронный ресурс]. URL: https://proaction.pro/glosarii/rynok_truda (дата обращения: 02.06.2025).
3. ЕЦП «Работа в России» Открытые данные // Наборы данных [Электронный ресурс]. URL: <https://trudvsem.ru/opendata/datasets> (дата обращения: 03.05.2025).
4. Коровкин А. Г. [и др.]. Об основных путях повышения эффективности использования трудового потенциала нашей страны. Москва, 2011.
5. Медицинская статистика МЕТОД КОЛМОГорова-СМИРнова // МЕТОД КОЛМОГорова-СМИРнова [Электронный ресурс]. URL: <https://medstatistic.ru/methods/methods10.html> (дата обращения: 03.06.2025).
6. Мирзабалаева Ф. И., Антонова Г. В. Структурные диспропорции спроса и предложения на рынке труда в отраслевом и профессионально-квалификационном разрезах // Russian Journal of Labor Economics. 2023. № 8 (10). С. 1145–1168.
7. Наталья Карташева Центр подготовки РКЦТ // Последствия дефицита специалистов на рынке труда и вызовы 2024 года [Электронный ресурс]. URL: <https://cdto.ranepa.ru/sum-of-tech/materials/178> (дата обращения: 03.05.2025).
8. Полякова М. В. СТРУКТУРНЫЕ ОСОБЕННОСТИ РЫНКА ТРУДА В МОСКВЕ // СИСТЕМНАЯ ПСИХОЛОГИЯ И СОЦИОЛОГИЯ. 2014. С. 118–122.

9. Сухинина Ю. А. НЕСООТВЕТСТВИЕ МЕЖДУ СПРОСОМ И ПРЕДЛОЖЕНИЕМ НА РЫНКЕ ТРУДА КАК ФАКТОР, ТОРМОЗЯЩИЙ ЭКОНОМИЧЕСКИЙ РОСТ. 2009.

10. Терников А. А., Шевелева Д. А. СПРОС И ПРЕДЛОЖЕНИЕ НА РЫНКЕ ТРУДА: ПОИСК ИСТОЧНИКОВ КОНФЛИКТА // Социологический Журнал. 2024. № 2 (30). С. 82–101.

11. ФИНЭКСПЕРТИЗА Доля российских работников с высшим образованием превысила треть // Доля российских работников с высшим образованием превысила треть [Электронный ресурс]. URL: <https://finexpertiza.ru/press-service/researches/2022/rab-vysh-obraz/> (дата обращения: 02.06.2025).

12. ЦБ РФ Доклад «Региональная экономика» // На рынке труда наметились признаки стабилизации.

13. Янников И. М., Ершова И. М., Исенбаев А. Н. Методы и алгоритмы для поиска сходства между текстами // Интеллектуальные системы в производстве. 2024. № 2 (22). С. 103–113.

14. Executive.ru Рынок труда: спрос и предложение // Рынок труда: спрос и предложение [Электронный ресурс]. URL: https://www.executive.ru/wiki/index.php/%D0%A0%D1%8B%D0%BD%D0%BE%D0%BA_%D1%82%D1%80%D1%83%D0%B4%D0%B0%3A_%D1%81%D0%BF%D1%80%D0%BE%D1%81_%D0%B8_%D0%BF%D1%80%D0%B5%D0%B4%D0%BB%D0%BE%D0%B6%D0%B5%D0%BD%D0%B8%D0%B5.com (дата обращения: 02.06.2025).

15. Grandars Рынок труда: понятие и функции // Рынок труда: понятие и функции [Электронный ресурс]. URL: <https://www.grandars.ru/student/ekonomicheskaya-teoriya/rynok-truda.html> (дата обращения: 03.06.2025).

16. RG.RU Эксперты рассказали, важен ли для работодателя уровень образования сотрудника // Эксперты рассказали, важен ли для работодателя уровень образования сотрудника [Электронный ресурс]. URL: <https://rg.ru/2024/06/27/miakish-bez-korochki.html> (дата обращения: 02.06.2025).

17. Sun J. [и др.]. Deep learning-based methods for natural hazard named entity recognition // Scientific Reports. 2022. № 1 (12).

ПРИЛОЖЕНИЯ

Приложение А

```
from scipy.stats import kstest
import numpy as np

def S(target: str, name: str):
    sphere_v = vacancies_df.query('professionRussian == @name')
    sphere_c = cv_df.query('professionRussian == @name')

    data = list(sphere_v[target].dropna())

    # Нормируем данные (обязательно!)
    data_standardized = (data - np.mean(data)) / np.std(data)

    data2 = list(sphere_c[target].dropna())
    data_standardized2 = (data2 - np.mean(data2)) / np.std(data2)

    statistic, p_value = kstest(data_standardized,
data_standardized2)

    return statistic
```

Приложение Б

```
def C(target: str, name: str):
    v_skills = vacancies_df.query('professionRussian ==
@name')[target].dropna()
    c_skills = cv_df.query('professionRussian ==
@name')[target].dropna()

    v_skills =
v_skills.str.split(',').explode().str.lower().str.strip()
    c_skills =
c_skills.str.split(',').explode().str.lower().str.strip()

    set_v = set(v_skills)
    set_c = set(c_skills)

    try:
        r = 2 * len(set_c.intersection(set_v)) / (len(set_v) +
len(set_c))
    except:
        r = 1
```

Приложение В

```
def L(target: str, name: str):
    new_df1 = vacancies_df.query('professionRussian ==
@name')[['responsibilities', 'qualifications']].dropna()
    new_df2 = cv_df.query('professionRussian ==
@name')['additionalInformation'].dropna()

    new_df1['vec'] = new_df1.apply(lambda x:
model.cpu().encode(x['responsibilities'] + ' ' +
x['qualifications'], convert_to_tensor=True), axis=1)
    new_df2['vec'] = new_df2.apply(lambda x: model.cpu().encode(x,
convert_to_tensor=True))

    sim = np.array([])
    for v1 in new_df1['vec']:
        for v2 in new_df2['vec']:
            sim = np.append(sim, util.pytorch_cos_sim(v1, v2))

    if sim.size == 0:
        return 1

    return 1 - sim.mean()
```